

## Л2 Условия оптимальности. Выпуклость и гладкость

Напомним, что ключевой задачей курса является (Л1.1). Начнем изучение с задачи без ограничений (безусловной задачи оптимизации):

$$\min_{x \in \mathbb{R}^d} f(x). \quad (\text{Л2.1})$$

Формализуем понятия решения данной задачи.

### Л2.1 Условия оптимальности

**Определение Л2.1.** Точка  $x^*$  называется *локальным минимумом* функции  $f$  на  $\mathbb{R}^d$  (локальным решением задачи минимизации  $f$  на  $\mathbb{R}^d$ ), если существует  $r > 0$  такое, что для любого  $y \in B_2^d(r, x^*) = \{y \in \mathbb{R}^d \mid \|y - x^*\|_2 \leq r\}$  следует, что  $f(x^*) \leq f(y)$ .

**Определение Л2.2.** Точка  $x^*$  называется *глобальным минимумом* функции  $f$  на  $\mathbb{R}^d$  (глобальным решением задачи минимизации  $f$  на  $\mathbb{R}^d$ ), если для любого  $x \in \mathbb{R}^d$  следует, что  $f(x^*) \leq f(x)$ .

Понятно, что глобальный минимум является одновременно и локальным. Попробуем понять, какие есть свойства локального минимума. В частности, следующая теорема приводит необходимое условие локального минимума безусловной задачи оптимизации (Л2.1).

**Теорема Л2.1** (Теорема 1.2.1. из [29]). Пусть  $x^*$  — локальный минимум функции  $f$  на  $\mathbb{R}^d$ . Тогда если  $f$  дифференцируема, то  $\nabla f(x^*) = 0$ .

*Доказательство.* Пойдем от противного и предположим, что  $x^*$  — локальный минимум, но  $\nabla f(x^*) \neq 0$ . Разложим функцию  $f$  в ряд в окрестности локального минимума:

$$f(x) = f(x^*) + \langle \nabla f(x^*), x - x^* \rangle + o(\|x - x^*\|_2), \quad (\text{Л2.2})$$

где  $\lim_{x \rightarrow x^*} \frac{o(\|x - x^*\|_2)}{\|x - x^*\|_2} = 0$ .

Рассмотрим  $x_\lambda = x^* - \lambda \nabla f(x^*)$ . Найдем  $\lambda_1 > 0$  такое, что для любого  $0 < \lambda \leq \lambda_1$  можно гарантировать, что  $\|x_\lambda - x^*\|_2 \leq r$ , т.е.  $x_\lambda$  попадает в нужную окрестность из определения локального минимума (Определение Л2.1). Понятно, что такое  $\lambda_1$  можно найти в силу  $r > 0$ , а  $\nabla f(x^*)$  конечно. Тогда для любого  $0 < \lambda \leq \lambda_1$  справедливо

$$f(x_\lambda) \geq f(x^*).$$

При этом разложение в ряд (Л2.2) для точек  $x_\lambda$  имеет вид:

$$\begin{aligned} f(x_\lambda) &= f(x^*) + \langle \nabla f(x^*), x_\lambda - x^* \rangle + o(\|x_\lambda - x^*\|_2) \\ &= f(x^*) - \lambda \|\nabla f(x^*)\|_2^2 + o(\lambda \|\nabla f(x^*)\|_2). \end{aligned}$$

Сделаем еще одно ограничение на «малость»  $\lambda$ . А именно, найдем  $\lambda_2 > 0$  такое, что для любого  $0 < \lambda \leq \min\{\lambda_1, \lambda_2\}$  выполнено

$$|o(\lambda \|\nabla f(x^*)\|_2)| \leq \frac{\lambda}{2} \|\nabla f(x^*)\|_2^2.$$

Тогда для любого  $\lambda > 0$  такого, что  $\lambda \leq \min\{\lambda_1, \lambda_2\}$ , следует

$$f(x_\lambda) \leq f(x^*) - \frac{\lambda}{2} \|\nabla f(x^*)\|_2^2.$$

Пришли к противоречию, что  $x^*$  — локальный минимум. А значит  $\nabla f(x^*) = 0$ . ■

Наша цель — находить глобальный минимум, а локальных хотелось бы наоборот избегать (зависит от конкретной задачи, но обычно цель именно такая). Как мы поняли в Параграфе Л1, без дополнительных предположений на задачу (Л1.1) в худшем случае полный равномерный перебор является оптимальным алгоритмом. Поэтому пора ввести новые понятия, которые помогут сузить класс изучаемых задач и построить оптимистичную теорию поиска глобального минимума.

## Л2.2 Выпуклость

Первое понятие — это выпуклость целевой функции  $f$  в задаче (Л2.1).

**Определение Л2.3.** Пусть дана непрерывно дифференцируемая на  $\mathbb{R}^d$  функция  $f : \mathbb{R}^d \rightarrow \mathbb{R}$ . Будем говорить, что она является *выпуклой*, если для любых  $x, y \in \mathbb{R}^d$  выполнено

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle.$$

Наряду с выпуклостью также вводят еще одно, более сильное понятие.

**Определение Л2.4.** Пусть дана непрерывно дифференцируемая на  $\mathbb{R}^d$  функция  $f : \mathbb{R}^d \rightarrow \mathbb{R}$ . Будем говорить, что она является  $\mu$ -*сильно выпуклой* ( $\mu > 0$ ), если для любых  $x, y \in \mathbb{R}^d$  выполнено

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \frac{\mu}{2} \|x - y\|_2^2.$$

Из определений видно, что выпуклость — это сильная выпуклость с  $\mu = 0$ .

В Параграфе С4 также даны другие определения выпуклости и сильной выпуклости, которые не требуют дифференцируемости. В случае дифференцируемой функции данные выше определения эквивалентны определениям из Параграфа С4.

Физический смысл Определений Л2.3 и Л2.4 проиллюстрирован на Рисунке Л2.1: выпуклая функция в любой точке «подперта» снизу линейно аппроксимацией, а сильно выпуклая — квадратичной функцией.

Введя новые классы функций, попробуем понять, что теперь можно сказать про точки минимума/решения задач оптимизации с такими целевыми функциями.

**Теорема Л2.2.** Пусть дана выпуклая на  $\mathbb{R}^d$  функция  $f : \mathbb{R}^d \rightarrow \mathbb{R}$ . Если для некоторой точки  $x^* \in \mathbb{R}^d$  верно, что  $\nabla f(x^*) = 0$ , то  $x^*$  — глобальный минимум  $f$  на всем  $\mathbb{R}^d$ .

*Доказательство.* Достаточно записать определение выпуклости:

$$f(x) \geq f(x^*) + \langle \nabla f(x^*), x - x^* \rangle = f(x^*).$$

■

Докажем несколько полезных фактов о минимумах выпуклых безусловных задач оптимизации.




Рис. 12.1: Иллюстрация понятий выпуклости и  $\mu$ -сильной выпуклости.

**Теорема 12.3.** Пусть дана выпуклая на  $\mathbb{R}^d$  функция  $f$ . Тогда

- всякий локальный минимум  $f$  на  $\mathbb{R}^d$  является и глобальным,
- если дополнительно  $f$  сильно выпуклая, то минимум существует и единственен.

*Доказательство.* Докажем последовательно пункты теоремы.

- Пусть  $x^*$  — локальный минимум. Согласно необходимому условию минимума функции (Теорема 12.1)

$$\nabla f(x^*) = 0.$$

Пусть также  $x$  — произвольная точка из  $\mathbb{R}^d$ . Воспользуемся выпуклостью  $f$ :

$$f(x) \geq f(x^*) + \langle \nabla f(x^*), x - x^* \rangle = f(x^*).$$

Получаем, что  $f(x^*) \leq f(x)$  для любого  $x \in \mathbb{R}^d$ . Значит,  $x^*$  — глобальный минимум.

- Покажем существование глобального минимума сильно выпуклой функции. Выберем произвольную точку  $x^0 \in \mathbb{R}^d$  и положим  $\beta = f(x^0)$ . Если  $\nabla f(x^0) = 0$ , то  $x^0$  — глобальный минимум (Теорема 12.2). Далее рассуждаем в предположении, что  $\nabla f(x^0) \neq 0$ . Рассмотрим множество подуровня функции  $f$ :

$$L_\beta = \left\{ x \in \mathbb{R}^d \mid f(x) \leq \beta \right\}.$$

По сильной выпуклости и неравенству Коши — Буняковского — Шварца (0.3) имеем:

$$\begin{aligned} f(x) &\geq f(x^0) + \langle \nabla f(x^0), x - x^0 \rangle + \frac{\mu}{2} \|x - x^0\|_2^2 \\ &\geq \beta - \|\nabla f(x^0)\|_2 \|x - x^0\|_2 + \frac{\mu}{2} \|x - x^0\|_2^2. \end{aligned}$$

Из условия  $f(x) \leq \beta$  вытекает:

$$\frac{\mu}{2} \|x - x^0\|_2^2 - \|\nabla f(x^0)\|_2 \|x - x^0\|_2 \leq 0 \implies \|x - x^0\|_2 \leq \frac{2\|\nabla f(x^0)\|_2}{\mu}.$$

Значит

$$L_\beta \subseteq B_R(x^0) = \left\{ x \in \mathbb{R}^d \mid \|x - x^0\|_2 \leq R \right\}, \text{ где } R = \frac{2\|\nabla f(x^0)\|_2}{\mu}.$$

Из этого вложения получаем, что вне шара  $B_R(x^0)$  значения функции  $f$  строго больше  $\beta$ :

$$f(x) > \beta, \quad \forall x \notin B_R(x^0).$$

При этом, шар  $B_R(x^0)$  замкнутый и ограниченный в конечномерном  $\mathbb{R}^d$ , следовательно, компактен. Тогда по теореме Вейерштрасса (см. Теорему 2 Параграфа 7 Главы 2 в [27])  $f$  достигает на  $B_R(x^0)$  своего минимума, который автоматически является глобальным (вне  $B_R(x^0)$  значения  $f$  больше  $\beta$ ).

Теперь покажем единственность. Пусть  $x^*$  — глобальный минимум,  $x \in \mathbb{R}^d$ . Поскольку  $f$  является  $\mu$ -сильно выпуклой:


$$\begin{aligned} f(x) &\geq f^* + \langle \nabla f(x^*), x - x^* \rangle + \frac{\mu}{2} \|x - x^*\|_2^2 \\ &= f^* + \frac{\mu}{2} \|x - x^*\|_2^2. \end{aligned}$$

Слагаемое с градиентом занулилось, поскольку в точке оптимума  $\nabla f(x^*) = 0$ . Из свойств нормы получаем, что  $f(x)$  достигает минимума только в точке  $x^*$ . Значит, если решение существует, то оно единственно. ■

Получается, что в случае выпуклой функции локальный минимум совпадает с глобальным. А значит  $\nabla f(x^*) = 0$  является необходимым и достаточным условием. В теореме не сказано про существование или единственность минимума выпуклой функции. Приведем два примера выпуклых функций, где эти свойства могут не выполняться.

**Пример Л2.1.** Покажем, что у выпуклой функции может быть больше одного минимума. Рассмотрим кусочно-заданную функцию  $f$ :

$$f(x) = \begin{cases} (x-1)^2, & x \in (1, +\infty) \\ 0, & x \in [-1, 1] \\ (x+1)^2, & x \in (-\infty, -1). \end{cases}$$



Она является выпуклой, однако, все точки отрезка  $[-1, 1]$  доставляют минимум  $f$ , то есть, у  $f$  бесчисленное количество точек минимума.

**Пример Л2.2.** Теперь приведем пример, когда выпуклая функция не имеет минимума на  $\mathbb{R}$ . Для этого подойдет линейная функция

$$f(x) = x.$$

Действительно, она выпукла, поскольку в каждой точке совпадает со своей линейной

аппроксимацией, при этом функция не ограничена снизу, поэтому ни одна из точек  $\mathbb{R}$  не является точкой минимума  $f$ .

### Л2.3 Гладкость

Введем еще одно свойство, которое также пригодится для того, чтобы строить теорию сходимости оптимизационных методов.

**Определение Л2.5.** Пусть дана непрерывно дифференцируемая на  $\mathbb{R}^d$  функция  $f : \mathbb{R}^d \rightarrow \mathbb{R}$ . Будем говорить, что данная функция имеет *L-Липшицев градиент* (говорить, что она является *L-гладкой*), если для любых  $x, y \in \mathbb{R}^d$  выполнено

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq L\|x - y\|_2.$$

Определение *L-гладкости* можно задавать и в не евклидовой норме. Обобщение понятия на произвольную норму мы введем в Параграфе Л9.

**Теорема Л2.4** (Лемма 1.2.3. из [29]). Пусть дана *L-гладкая* непрерывно дифференцируемая на  $\mathbb{R}^d$  функция  $f : \mathbb{R}^d \rightarrow \mathbb{R}$ . Тогда для любых  $x, y \in \mathbb{R}^d$  выполнено

$$|f(y) - f(x) - \langle \nabla f(x), y - x \rangle| \leq \frac{L}{2}\|x - y\|_2^2.$$

*Доказательство.* Используем (см. страницу 84 из [28]) формулу Ньютона-Лейбница для криволинейного интеграла второго рода по кривой, заданной вектор функцией  $r(\tau)$ :

$$\int_a^b \langle \nabla f(r(\tau)), dr(\tau) \rangle = f(r(b)) - f(r(a)).$$

В нашем случае выберем кривую следующим образом  $r(\tau) = x + \tau(y - x)$ , где  $\tau \in [0, 1]$ . Тогда

$$\begin{aligned} f(y) - f(x) &= \int_0^1 \langle \nabla f(x + \tau(y - x)), y - x \rangle d\tau \\ &= \langle \nabla f(x), y - x \rangle + \int_0^1 \langle \nabla f(x + \tau(y - x)) - \nabla f(x), y - x \rangle d\tau. \end{aligned}$$

Переместив скалярное произведение влево и взяв модуль от обеих частей, получим:

$$\begin{aligned} |f(y) - f(x) - \langle \nabla f(x), y - x \rangle| &= \left| \int_0^1 \langle \nabla f(x + \tau(y - x)) - \nabla f(x), y - x \rangle d\tau \right| \\ &\leq \int_0^1 |\langle \nabla f(x + \tau(y - x)) - \nabla f(x), y - x \rangle| d\tau. \end{aligned}$$

В последнем переходе мы использовали факт, что модуль суммы не превосходит сумму модулей слагаемых. Далее воспользуемся неравенством Коши — Буняковского — Шварца (0.3), а затем  $L$ -гладкостью (Определение Л2.5):

$$\begin{aligned} |f(y) - f(x) - \langle \nabla f(x), y - x \rangle| &\leq \int_0^1 \|\nabla f(x + \tau(y - x)) - \nabla f(x)\|_2 \|y - x\|_2 d\tau \\ &\leq L \|y - x\|_2^2 \int_0^1 \tau d\tau = \frac{L}{2} \|x - y\|_2^2. \end{aligned}$$

■

Отметим, что Теорема Л2.4 требует только  $L$ -гладкости функции  $f$ . Посмотрим, что можно получить, если дополнительно предположить еще и выпуклость функции  $f$ .

**Теорема Л2.5** (Теорема 2.1.5. из [29]). Непрерывно дифференцируемая функция  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  является выпуклой и  $L$ -гладкой тогда и только тогда, когда для любых  $x, y \in \mathbb{R}^d$  выполнены следующие неравенства:

$$0 \leq f(y) - f(x) - \langle \nabla f(x), y - x \rangle \leq \frac{L}{2} \|x - y\|_2^2, \quad (\text{Л2.3})$$

$$\frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) - f(x) - \langle \nabla f(x), y - x \rangle, \quad (\text{Л2.4})$$

$$\frac{1}{L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq \langle \nabla f(x) - \nabla f(y), x - y \rangle. \quad (\text{Л2.5})$$

*Доказательство.* Докажем следующее:

$$\left\{ \begin{array}{l} \text{выпуклость} \\ \text{гладкость} \end{array} \right\} \implies (\text{Л2.3}) \implies (\text{Л2.4}) \implies (\text{Л2.5}) \implies \left\{ \begin{array}{l} \text{выпуклость} \\ \text{гладкость} \end{array} \right\}$$

**Выпуклость + гладкость  $\implies$  (Л2.3).** Первое неравенство есть просто определение выпуклости, а второе является следствием из Теоремы Л2.4.

**(Л2.3)  $\implies$  (Л2.4).** Рассмотрим  $\phi(y) = f(y) - \langle \nabla f(x), y \rangle$  для некоторого фиксированного  $x \in \mathbb{R}^d$ . Удостоверимся, что  $\nabla \phi(y) = \nabla f(y) - \nabla f(x)$  является  $L$ -гладкой:

$$\begin{aligned} \|\nabla \phi(y_1) - \nabla \phi(y_2)\|_2 &= \|\nabla f(y_1) - \nabla f(x) - \nabla f(y_2) + \nabla f(x)\|_2 \\ &= \|\nabla f(y_1) - \nabla f(y_2)\|_2 \leq L \|y_1 - y_2\|_2. \end{aligned}$$

Проверим также, что  $\phi(y)$  выпуклая (по определению). Так как  $f$  выпуклая, для произвольных  $y_1$  и  $y_2$  имеем:

$$\begin{aligned} f(y_1) &\geq f(y_2) + \langle \nabla f(y_2), y_1 - y_2 \rangle \\ &\Updownarrow \\ f(y_1) - \langle \nabla f(x), y_1 \rangle &\geq f(y_2) - \langle \nabla f(x), y_2 \rangle + \langle \nabla f(y_2) - \nabla f(x), y_1 - y_2 \rangle \\ &\Updownarrow \\ \phi(y_1) &\geq \phi(y_2) + \langle \nabla \phi(y_2), y_1 - y_2 \rangle. \end{aligned}$$

А это и есть выпуклость  $\phi(y)$ . Заметим, что  $\nabla\phi(x) = 0$ , тогда в силу того, что функция  $\phi$  выпуклая, то  $y^* = x$  — точка глобального минимума (Теорему Л2.2). Откуда

$$\phi(x) = \phi(y^*) \leq \phi\left(y - \frac{1}{L}\nabla\phi(y)\right). \quad (\text{Л2.6})$$

Теперь применим первый пункт теоремы для  $f \rightarrow \phi$ ,  $y \rightarrow y - \frac{1}{L}\nabla\phi(y)$ ,  $x \rightarrow y$ :

$$\phi\left(y - \frac{1}{L}\nabla\phi(y)\right) - \phi(y) - \left\langle \nabla\phi(y), -\frac{1}{L}\nabla\phi(y) \right\rangle \leq \frac{1}{2L}\|\nabla\phi(y)\|_2^2,$$

а значит после небольшой перестановки получим:

$$\phi\left(y - \frac{1}{L}\nabla\phi(y)\right) \leq \phi(y) - \frac{1}{2L}\|\nabla\phi(y)\|_2^2. \quad (\text{Л2.7})$$

Осталось объединить (Л2.6) и (Л2.7):

$$\phi(x) \leq \phi(y) - \frac{1}{2L}\|\nabla\phi(y)\|_2^2,$$

и подставить  $\phi$ :

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2.$$

Из этого легко получить то, что и хотели доказать

$$\frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) - f(x) - \langle \nabla f(x), y - x \rangle.$$

(Л2.4)  $\implies$  (Л2.5). Запишем два раза (Л2.4):

$$\begin{aligned} \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 &\leq f(y) - f(x) - \langle \nabla f(x), y - x \rangle, \\ \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2 &\leq f(x) - f(y) - \langle \nabla f(y), x - y \rangle. \end{aligned}$$

Сложим эти два неравенства:

$$\frac{1}{L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq \langle \nabla f(x) - \nabla f(y), x - y \rangle.$$

(Л2.5)  $\implies$  **выпуклость + гладкость**. Из (Л2.5) имеем, что:

$$0 \leq \langle \nabla f(x) - \nabla f(y), x - y \rangle.$$

Снова применим (см. страницу 84 из [28]) формулу Ньютона-Лейбница для криволинейного интеграла второго рода по кривой, заданной вектор функцией  $r(\tau)$ :

$$\int_a^b \langle \nabla f(r(\tau)), dr(\tau) \rangle = f(r(b)) - f(r(a)).$$

В нашем случае выберем кривую следующим образом  $r(\tau) = x + \tau(y - x)$ , где  $\tau \in [0, 1]$ :

$$\begin{aligned} f(y) - f(x) &= \int_0^1 \langle \nabla f(x + \tau(y - x)), y - x \rangle d\tau \\ &= \langle \nabla f(x), y - x \rangle + \int_0^1 \langle \nabla f(x + \tau(y - x)) - \nabla f(x), y - x \rangle d\tau. \end{aligned}$$

Используя, что  $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq 0$ , получим:

$$\begin{aligned} f(y) - f(x) &= \langle \nabla f(x), y - x \rangle + \int_0^1 \frac{1}{\tau} \cdot \langle \nabla f(x + \tau(y - x)) - \nabla f(x), \tau(y - x) \rangle d\tau \\ &\geq \langle \nabla f(x), y - x \rangle. \end{aligned}$$

А это и есть эквивалентное определение выпуклости для непрерывно дифференцируемой функции. Также (Л2.5) вместе с неравенством Коши — Буняковского — Шварца (0.3) дает:

$$\begin{aligned} \frac{1}{L} \|\nabla f(x) - \nabla f(y)\|_2^2 &\leq \langle \nabla f(x) - \nabla f(y), x - y \rangle \\ &\leq \|\nabla f(x) - \nabla f(y)\|_2 \cdot \|x - y\|_2. \end{aligned}$$

Откуда

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq L \|x - y\|_2,$$

а это и есть Определение Л2.5. ■

Первое неравенство из Теоремы Л2.5 может быть полезно в понимании физического смысла  $L$ -гладкости (Рисунок Л2.2): функция «подперта» снизу линейной аппроксимацией, а сверху квадратичной функцией. Похожая ситуация с  $L$ -гладкой и  $\mu$ -сильно выпуклой функцией. Из Теоремы Л2.5 и Определения Л2.4 легко заметить, что  $L \geq \mu$ .




Рис. Л2.2: Иллюстрация выпуклости,  $\mu$ -сильной выпуклости и  $L$ -гладкости.



**Упражнение 11.1.** Рассмотрите квадратичную функцию:

$$f(x) = \frac{1}{2} \langle x, Ax \rangle - \langle b, x \rangle,$$

где  $b, x \in \mathbb{R}^d$ ,  $A \in \mathbb{S}_+^d$ . Покажите, что константы сильной выпуклости и гладкости можно оценить:

$$\mu \leq \frac{1}{2} \lambda_{\min}(A + A^\top), \quad L \geq \frac{1}{2} \lambda_{\max}(A + A^\top).$$

**Упражнение 11.2.** Рассмотрите логистическую функцию потерь:

$$f(x) = -\frac{1}{n} \sum_{i=1}^n l(g(x, a_i), b_i) + \frac{\lambda}{2} \|x\|_2^2,$$

где  $g : \mathbb{R}^d \times \mathbb{R}^d \rightarrow \{0, 1\}$  — классификатор:

$$g(x, a_i) = \frac{1}{1 + \exp(-\langle x, a_i \rangle)},$$

а  $l : \mathbb{R}^d \times \mathbb{R}^d \rightarrow [0, +\infty]$  — бинарная кросс-энтропия:

$$l(x, y) = y \ln x + (1 - y) \ln(1 - x),$$

$a_i \in \mathbb{R}^d$ ,  $b_i \in \{0, 1\}$ ,  $i = \overline{1, n}$  — данные,  $x \in \mathbb{R}^d$  — целевая переменная,  $\lambda \in \mathbb{R}_+$  — параметр регуляризации. Покажите, что константы сильной выпуклости и гладкости можно оценить:

$$\mu \leq \frac{1}{n} \lambda_{\min}(AA^\top) + \lambda, \quad L \geq \frac{1}{n} \lambda_{\max}(AA^\top) + \lambda.$$